

# 基于智能优化算法的 T-S 模糊模型辨识

刘福才, 窦金梅, 王树恩

(燕山大学工业计算机控制工程河北省重点实验室, 河北 秦皇岛 066004)

**摘要:** 将智能算法应用在 T-S 模糊模型的辨识方面, 是模糊系统辨识的一种新途径。文中对几种智能优化算法, 如遗传算法 (genetic algorithm, GA)、粒子群 (particle swarm optimization, PSO) 算法、菌群优化 (bacterial foraging optimization, BFO) 算法等的优化原理和在模糊辨识方面的应用现状进行了综述和分析, 并给出了它们在 T-S 模糊模型辨识中对参数进行优化的过程。最后将这些优化方法用于一非线性动态系统的建模, 并对仿真结果进行了对比和详细的分析, 为进一步了解这几种优化方法在模糊模型辨识参数优化方面的作用提供了仿真实验依据。

**关键词:** T-S 模型辨识; 群智能算法; 遗传算法; 菌群优化算法; 粒子群算法

**中图分类号:** TP 273.4

**文献标志码:** A

**DOI:**10.3969/j.issn.1001-506X.2013.12.31

## T-S fuzzy model identification based on intelligent optimization algorithms

LIU Fu-cai, DOU Jin-mei, Wang Shu-en

(Key Laboratory of Industrial Computer Control Engineering of Hebei Province,  
Yanshan University, Qinhuangdao 066004, China)

**Abstract:** It is a new way apply intelligent algorithms to the identification of T-S fuzzy systems. This paper gives a detail description of several intelligent optimization algorithms and their application of fuzzy identification, such as genetic algorithm (GA), particle swarm optimization (PSO) algorithm and bacterial foraging optimization (BFO) algorithm. The parameters optimization processes of these algorithms on the T-S fuzzy model are also provided. Finally, the described methods are applied to the modeling of a nonlinear dynamic system, and the simulation results are analyzed in detail. This paper provides an opportunity for a further understanding of the effects of these methods on the process of parameters optimization in fuzzy modeling.

**Keywords:** T-S fuzzy model identification; population-based intelligent optimization (PIO) algorithm; genetic algorithm (GA); bacterial foraging optimization (BFO) algorithm; particle swarm optimization (PSO) algorithm

## 0 引言

自 1985 年 Takagi 和 Sugeno 提出 T-S 模糊模型的 30 年以来, 国内外相关学者对 T-S 模糊模型的辨识方法及应用领域进行了深入的研究。主要研究内容包括前提结构辨识(输入变量的选择, 模糊子空间的线性与非线性划分, 隶属函数的确定)和参数辨识, 结论参数辨识(主要是递推最小二乘法(recursive least square, RLS))<sup>[1-2]</sup>, 模糊库优化, 收敛性分析等<sup>[3]</sup>。随着诸多智能优化算法的提出, 将优化算法应用到 T-S 模型辨识中, 是近几年模糊辨识领域的一个新研究方向。这些算法的应用确实提高了模型逼近精度, 但如何更好地利用这些优化算法, 将是本文所要解决的一个主要问题。本文通过数值仿真分析了几种常用优化算

法的优缺点, 为以后在模糊模型参数优化方面合理应用智能优化算法提供了一些合理的实验指导。

作为一类最优化智能算法, 智能仿生算法模仿的是大自然里生物优化其生活环境的过程, 它们完全遵从个体的本能反应, 进行下意识的搜索。智能仿生算法对需要求解的问题本身的严格数学性质要求并不高, 它是一种全局算法, 依靠多个个体搜索求解, 其概率求解、并行计算、高效自适应和演化性等特点使得它在求解复杂问题时处于优势地位<sup>[4]</sup>。

从群居生物的相互协调工作获得生存资源中得到启迪, 群智能优化(population-based intelligent optimization, PIO)算法作为智能仿生算法的成员, 人们对其基本思想进行了研究, 提出了一些复杂问题的求解新方法, 如遗传算法

(genetic algorithm, GA)、粒子群(particle swarm optimization, PSO)算法、菌群优化(bacterial foraging optimization, BFO)算法<sup>[4]</sup>等。每一种具体的 PIO 算法的机制,大部分都是生物个体或社会行为中提取,PIO 算法的操作和参数决定了它的寻优过程行为。社会合作、自我适应和相互竞争这三个基础行为构成了 PIO 的迭代求解过程。在求解过程中,生物个体的相互交换信息和学习即为社会合作,如 PSO 中的个体根据种群历史最优位置优化本身位置;不需了解其他个体的情况,通过调节个体本身的生存状态来更佳地融入生活环境,即为自我适应,如 PSO 中个体根据自身历史最优位置等信息对其速度和方向进行调节;搜索中的群体自我更新即为竞争,也就是说新种群中好的个体能够存活下来的几率更大些,如 PSO 中的更新操作<sup>[5]</sup>。

研究表明现有的群智能算法都或多或少地存在“早熟”、“晚熟”甚至“不熟”的收敛性缺陷和问题,因此学者们将研究方向投向了在不同的群智能算法之间取长补短来改进优化算法性能的途径,并与其他算法相结合寻找发展方向。如文献[6]中用 PSO 和 GA 的混合算法优化能源需求估计模型,以此提高对未来预测的估计效率,文中用 PSO-GA 优化线性、指数、二次方程 3 种形式的模型参数。文献[7]将 BFO 和 RLS 组合算法用于失真电力系统谐波估计,对电力系统电压或电流波形中的基础部分和谐波部分进行了估计。文献[8]分别基于 BFO 和 PSO 两种算法优化功能链接人工神经网络来有效辨识复杂非线性动态系统。而将智能优化算法与模糊辨识相结合,应用于模糊系统辨识,是智能算法发展的一个方向,也是模糊辨识的一种新途径。文献[9]采用 T-S 模糊模型,基于 PSO 和 RLS 算法提出了一种模糊自适应函数逼近器,基于输入输出数据对非线性函数进行逼近。文献[10]将 PSO 的优点融入到 BFO 中,形成 BSO 算法,使二者的优点结合起来,有效实现了非线性系统的模糊控制。文献[11]基于 PSO 和最大熵原则设计优化模糊规则库,用数据驱动进行模糊聚类,最大熵原则优化输出变量隶属度,PSO 优化模糊规则中心。

T-S 模型是常用的一种模糊模型,可用少量的模糊规则生成复杂的非线性函数,其后件是一个确定的多项式,利用学习算法可求出多项式的参数。所以,本文采用 T-S 模糊模型进行系统的辨识,主要针对 T-S 模糊模型与智能优化算法的结合问题进行研究。

## 1 T-S 模糊模型

Takagi T 和 Sugeno M 于 1985 年建立了 T-S 模糊模型,其模糊蕴含条件句为<sup>[12]</sup>

$$R^i: \text{if } x_1 \text{ is } A_1^i \text{ and } x_2 \text{ is } A_2^i \text{ and } \cdots \text{ and } x_r \text{ is } A_r^i, \\ \text{then } y^i = p_0^i + p_1^i x_1 + \cdots + p_r^i x_r \quad (1)$$

式中,  $i=1,2,\cdots,c$  为第  $i$  条模糊规则;  $x_j$  ( $j=1,2,\cdots,r$ ) 是第  $j$  个输入变量;  $A_j^i$  是一个模糊集合;  $y^i$  是第  $i$  条规则的输出;  $p_j^i$  是结论参数。

采用如下的高斯型隶属函数:

$$A_j^i(x_j) = \exp\left(-\left(\frac{x_j - m_j^i}{\sigma_j^i}\right)^2\right) \quad (2)$$

式中,  $m_j^i$  为隶属函数中心;  $\sigma_j^i$  为隶属函数宽度。

可采用智能优化算法对高斯型隶属函数的参数  $m_j^i$  和  $\sigma_j^i$  进行优化。

对每条模糊规则的输出  $y^i$  ( $i=1,2,\cdots,c$ ) 利用中心平均解模糊法可求出模型总输出  $\hat{y}$  为

$$\hat{y} = \frac{\sum_{i=1}^c \mu_i y^i}{\sum_{i=1}^c \mu_i} = \frac{\sum_{i=1}^c \omega_i y^i}{\sum_{i=1}^c \omega_i} = \frac{\sum_{i=1}^c \omega_i (p_0^i + p_1^i x_1 + \cdots + p_r^i x_r)}{\sum_{i=1}^c \omega_i} \quad (3)$$

式中,  $\mu_i = \prod_{j=1}^r A_j^i(x_j)$  ( $i=1,2,\cdots,c$ ) 为关于  $x_j$  的第  $i$  条模糊规则的权值;  $\prod$  是模糊算子,通常采用取小运算或乘积运算,本文采用取小运算;  $\omega_i = \mu_i / \sum_{i=1}^c \mu_i$ 。

## 2 优化算法

### 2.1 遗传算法

1975 年,美国密西根大学的 Holland 教授与学生创造出了 GA,它是一种基于生物和进化机制,适合复杂系统优化计算的自适应概率优化技术<sup>[13]</sup>。图 1 为标准遗传算法的流程图。GA 有 3 个典型算子:选择、交叉和变异。交叉概率为  $p_c$ ,变异概率为  $p_m$ 。




图 1 标准 GA 流程图

GA 是一种不需求导、并行计算、全局优化的搜索算法,已经有了比较完整的数学理论,是成熟的函数优化算法。GA 在 80 年代末和 90 年代初兴起,此期间,大量学者在其专著和论文中阐述和应用了遗传算法。如文献[14]中采用模糊聚类法优化模糊模型前提结构,GA 优化前件参数,最小二乘法优化结论参数。文献[15]直接在数据集中用 GA 产生和调整规则,用模糊聚类法粗略估计出模糊规则并作为 GA 的初始群体的一部分以加速算法的收敛性和快速性。近年来,基于遗传算法的系统辨识方法引起了许多研究者的兴趣。如文献[16]基于 T-S 模糊模型提出一种

工业应用的软传感器设计,该方法采用进化遗传算法,通过输入输出数据学习 T-S 模糊模型来逼近未知非线性过程。文献[17]用 GA 辨识 TSK(Takagi-Sugeno-Kang)模型,优化 TSK 模型结构,具有简单、灵活、精度高、自适应性强的特点。文献[18]用改进的 GA 优化 BP 神经网络权值和阈值,训练 BP 神经网络模型求得最优解,并用于混沌时间序列预测。文献[19]用 GA 和 RLS 的组合算法优化 T-S 模糊模型,对非线性控制过程进行建模。

研究表明,GA 可为系统辨识提供一种简单而有效的方法。GA 的 3 个典型操作并不遵循特定规则,均为随机行为,因此 GA 是采用随机方法进行最优解搜索的。

T-S 模糊模型参数优化时,采用均方误差 (means square error, MSE) 作为目标函数

$$MSE = \frac{1}{N_1} \sum_{k=1}^{N_1} (y(k) - \hat{y}(k))^2 \quad (4)$$

式中,  $\hat{y}(k)$  为模糊模型输出;  $y(k)$  为时间输出;  $N_1$  为总的采样次数。

遗传算法选择操作时,是按照个体的适应度越高,被选择的概率越大的原则进行的,因此,适应度函数可设计为

$$fitness = \frac{1}{\xi + MSE} \quad (5)$$

式中,  $\xi$  通常选取一个较小的正实数,这样可以避免除数为零的情况发生。

GA 需要选择的参数有:种群规模  $S$ 、交叉概率  $p_c$  和变异概率  $p_m$ 。参数选择的不同导致遗传算法计算结果有很大的差异,许多学者对如何选择合适的 GA 参数进行了研究,目前常用的参数范围为<sup>[20]</sup>:  $S=20 \sim 160$ ,  $p_c=0.5 \sim 1.0$ ,  $p_m=0.005 \sim 0.1$ 。在此范围内,GA 的优化性能较好。

2.2 粒子群优化算法

Kennedy 和 Eberhart 于 1995 年提出的 PSO 算法是一种启发式全局优化算法<sup>[21]</sup>。它的基本思想是模拟动物的简单社会行为,如鸟类的聚集行为。PSO 算法也是一种群体优化工具,这点类似于 GA,但 PSO 是粒子跟踪解空间的最好粒子来搜索,避免了遗传算法后两步操作,实现简单、方便,能够快速收敛到最优值,在解决一些典型的复杂函数优化问题时,PSO 比 GA 有更好的优化结果。

随机地初始化 PSO 粒子种群,然后迭代求解。每一次迭代,微粒追随粒子个体的最优解(个体最优值)  $P_{id}$  和种群的历史最优解(全局最优值)  $P_{gd}$  来更新速度与位置,图 2 表示的是粒子位置更新的过程。每个粒子都有一个速度,记作  $V$ ,定义为

$$V_{id}(t+1) = \omega \cdot V_{id} + c1 \cdot rand \cdot (P_{id}(t) - X_{id}(t)) + c2 \cdot rand \cdot (P_{gd}(t) - X_{id}(t)) \quad (6)$$

式中,  $V_{id}$  表示第  $i$  个粒子在第  $d$  维上的速度;  $\omega$  为惯性权重;  $c1, c2$  为调节  $P_{id}$  和  $P_{gd}$  相对重要性的参数;  $rand$  生成介于 0 和 1 之间的随机数。这样可以得到粒子的下一个位置

$$X_{id}(t+1) = X_{id}(t) + V_{id}(t+1) \quad (7)$$

粒子速度由 3 部分决定:原有速度  $V_{id}$ 、与个体最佳经历的距离  $P_{id} - X_{id}$  和与群体最佳经历的距离  $P_{gd} - X_{id}$ , 分别由权重系数  $\omega, c1, c2$  来决定其相对重要性。PSO 算法包含下列步骤:

- 步骤 1 计算每个粒子的适应度函数;
- 步骤 2 更新个体和全局最佳适应度和位置;
- 步骤 3 更新每个粒子的速度和位置。




图 2 粒子位置更新示意图

在判断粒子位置时,距离最佳经历的距离越小越好,因此,可以选择目标函数 MSE 作为适应度函数。

作为一种较成熟的进化算法,近年来学者对 PSO 算法的应用和理论研究很多,已经成为一大研究热点。文献[22]用改进的 PSO 算法进行现场可编程门阵列动态系统神经网络辨识,在 PSO 速度更新方程中加入一个附加项来调整速度,以减少搜索陷入局部最小值的可能,结果说明仅靠增加少量的硬件设备,该方法就可以更快的收敛,并且有更高的精度。文献[23]总结了 PSO 技术优化加工过程参数(自 2007 年至 2011 年的传统和现代的加工工艺所有参数)结果。文献[24]将 PSO 算法用于多目标函数非线性约束投资组合优化问题,初步研究结果表明该方法有较高的计算效率,较其他方法有更好的应用前景。而文献[25]中用 PSO 和神经网络辨识非线性复杂系统。文献[26]提出了改进的 PSO 算法,克隆 PSO 和免疫 PSO,分别用于哈默斯坦系统的辨识,两种方法都有较低的复杂度和较好的辨识效果,结果表明,较其他方法免疫 PSO 算法辨识效果最好。PSO 在模糊系统辨识问题方面的应用也已经有了很多研究成果。如文献[27]用 PSO 增强进化算法优化模糊 PID 控制器的参数,该方法可以减少进化代数,而且可以进一步优化模糊系统以使其达到更优。文献[28]用符合自然性质的扩展 PSO 算法求解组合优化问题,这种算法基于平衡模糊集理论,此理论中无论正的还是负的隶属函数信息都是同等重要的。文献[29]用 PSO 算法优化模糊 PID 控制器来解耦高度互动净化过程,提高了系统瞬态和稳态特性。文献[30]采用语言模糊模型,用不同粒子长度的 PSO 算法来对非线性函数和时间序列建模,由文中所提的 PSO 算法自动地产生模糊规则库的结构和参数。文献[31]提出一种改进的 PSO 算法——协作随机学习 PSO,基于随机学习 PSO 将 T-S 模糊结构和参数编码为一个粒子,共同进化以达到同时优化模糊模型结构和参数的目的,实现从数据中自动提取 T-S 模糊模型。

### 2.3 菌群优化算法

Liu 和 Passino 于 2002 年提出了一种新的进化算法——菌群优化算法<sup>[32]</sup>,其算法简单、收敛速度快、精度高、资源占用率较低、局部搜索能力强。优化过程中,BFO 采用分布式无梯度搜索,有较强的通用性。与 GA 相比,BFO 不仅计算简单,而且计算量小,辨识精度有所提高。

BFO 算法理论基础薄弱,但在应用方面已经做了一些研究。文献[33]中将 BFO 算法用于边缘检测技术,文中将 BFO 算法和蚁群系统的概率导数技术组合起来进行边缘检测。文献[34]用基于静态无功补偿器的 BFO 算法来抑制多机电力系统震荡,BFO 算法通过最小化时域目标函数搜索最优控制器参数。文献[35]应用大肠杆菌的趋药性行为,解决多目标优化问题。文献[36]应用 BFO 和模糊决策,辨识电容器在一个离散径向系统中的最佳位置和数量。

BFO 中需要确定的参数有:在趋向性算子里,细菌沿同一方向前进的步数  $N_s$ ,菌群规模数  $S$ ,搜索空间维数  $D$  (需优化变量个数),趋向性行为步数  $N_c$ ,繁殖代数  $N_r$ ,迁徙事件数目  $N_{el}$ ,迁徙概率  $P_{el}$  等。 $S$  为 BFO 算法的细菌个数,与搜索维数  $D$  相关, $S$  增大,BFO 的求解能力增强,但计算量增大且没有明显效果,因此通常采用较小的  $S$ 。通过阅读大量 BFO 算法相关文献,得出其参数的取值范围为<sup>[37]</sup>: $N_s=3\sim 8$ , $P_{el}=0.05\sim 0.3$ , $N_{el}=(0.15\sim 0.25)N_r$ , $d_{attractant}=0.01\sim 0.1$ , $w_{attractant}=0.01\sim 0.2$ , $h_{repellant}=d_{attractant}$ , $w_{repellant}=2\sim 10$ 。

在 BFO 中,细菌经过 4 步完成目标的优化:趋向性行为、聚集、繁殖和迁徙行为。经历这 4 步后,细菌实现觅食过程(即寻找到最优解)<sup>[32]</sup>。

细菌种群的 4 个行为分别描述如下:

#### (1) 趋向性行为(chemotaxis)

趋向性就是细菌对环境的应激反应。前进、翻转两种运动模拟细菌此行为。沿与上一步运动的方向同向运动即为前进,沿与上一步运动的方向不同向运动即为翻转。在计算趋向性的过程中,细菌的运动可被表示为

$$\theta^i(j+1,k,l) = \theta^i(j,k,l) + C(i)(\Delta(i)/\text{Sqrt}(\Delta^T(i)\Delta(i))) \quad (8)$$

式中, $\theta^i$ , $C(i)$ , $\Delta$  分别表示位置,步长,随机方向;细菌的趋向性指数  $j=1:N_c$ ;繁殖指数  $k=1:N_r$ ;淘汰指数  $l=1:N_{el}$ 。

#### (2) 聚集行为(swarming)

模拟细菌间的相互通信,互相通知附近的营养物质和有毒物质。通过引力和斥力使细菌聚集并获得能量。细菌间聚集作用的数学表达式为

$$J_{cc}(\theta) = \sum_{i=1}^S J_{cc}^i(\theta) = \sum_{i=1}^S [-d_{attractant} \exp(-w_{attractant} \sum_{m=1}^D (\theta_m - \theta_m^i)^2)] + \sum_{i=1}^S [h_{repellant} \exp(-w_{repellant} \sum_{m=1}^D (\theta_m - \theta_m^i)^2)] \quad (9)$$

式中, $S$  为菌群规模数; $D$  为搜索空间维数; $\theta_m$  表示菌体位置中第  $m$  个元位置, $m=1,\dots,\rho$ ;  $d_{attractant}$  和  $w_{attractant}$  分别为细菌间引力深度和宽度;  $h_{repellant}$  和  $w_{repellant}$  分别为细菌间斥力

高度和宽度。

#### (3) 繁殖行为(reproduction)

繁殖行为通过健康函数选择出要进化繁殖的细菌,淘汰较差个体。为了避免算法的复杂性,保持菌群规模不变。

#### (4) 迁徙行为(elimination and dispersal)

迁徙行为对细菌被消灭或疏散到新的区域这一过程进行模拟,以概率  $P_{el}$  将同等数目的细菌重新随机分布到寻优区间。迁徙行为可以有效地避免寻优过程陷入局部寻优。

菌群优化算法流程如图 3 所示。

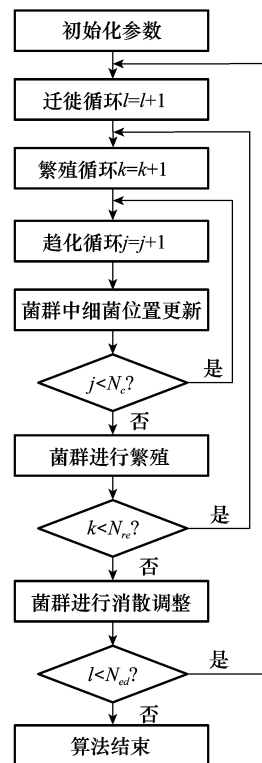


图 3 BFO 算法流程图

在 BFO 算法中,细菌与最优位置的距离越小越好,因此可以选择 MSE 作为算法的适应度函数。

### 2.4 基于粒子群算法的菌群优化算法(BSO)

BFO 个体之间信息交换能力小,影响收敛结果,而 PSO 具有良好的信息交换能力,所以在迁徙环节将 PSO 粒子的社会学习思想引入 BFO 中来更新细菌位置,而不是借助迁徙概率  $P_{el}$  更新,从而加强了粒子间的“信息交流”,增强了 BFO 算法的全局搜索能力,有助于 BFO 跳出局部最优,提高收敛精度<sup>[10]</sup>。在迁徙环节中,为每个细菌考虑了一个速率值,随机初始化种群。PSO 算法采用式(10)所示方程

$$V_{id}^{new} = w \cdot V_{id}^{old} + c_1 \varphi_1 (\theta_{g-bestd} - \theta_{id}^{old}(i,j+1,k)) \quad (10)$$

$$\theta_{id}^{new}(i,j+1,k) = \theta_{id}^{old}(i,j+1,k) + V_{id}^{new}$$

式中, $V_{id}$  表示第  $i$  个粒子第  $d$  维上的速度; $w$  为惯性权重; $c_1$  为调节  $P_{id}$  和  $P_{gd}$  相对重要性的参数; $\varphi_1$  为介于 0 和 1 之间的随机数。

2.5 PSO-RLSE 算法

粒子群-递推最小二乘 (particle swarm optimization-recursive squares error, PSO-RLSE) 算法是一种新的自适应模糊函数逼近方法<sup>[9]</sup>, 采用 T-S 模糊模型, 将需要优化的参数分成两个部分, 前提部分和结论部分, 采用 PSO 算法优化模糊系统的前提部分, RLSE 算法优化模糊系统的结论部分, 该学习算法有很好的收敛性。

3 仿真研究

将非线性动态系统作为仿真对象, 可用以下的微分方程描述:

$$y(k+1) = \frac{y(k)}{1+y^2(k)} + u^3(k) \tag{15}$$

输入数据由  $u(k) = \sin(2k\pi/100)$  产生, 训练样本的输入为  $[u(k), y(k), y(k-1)]^T$ , 期望输出为  $y(k+1)$ , 初始值为  $y(1)=0$ , 训练数据 500 组。对该非线性系统建立 T-S 模糊模型, 取模糊划分数为  $c=4$ 。这里选择的优化算法的参数均在文献通常采用的参数范围内。

优化算法的参数选择:

- (1) 遗传算法参数<sup>[20]</sup>: 种群规模  $N=40$ ; 最大遗传代数  $mds=100$ ; 变量的二进制位数  $gt=20$ ; 代沟  $d_g=0.95$ ; 交叉概率  $p_c=0.95$ ; 变异概率  $p_m=0.005$ 。
- (2) PSO 算法参数<sup>[4,28]</sup>: 初始化群体个体数目  $N=40$ ; 学习因子  $c1=1.496\ 2, c2=1.496\ 2$ ; 惯性权重  $\omega=0.729\ 8$ ; 最大迭代次数  $\max DT=1\ 000$ 。
- (3) BFO 算法参数<sup>[37]</sup>: 种群规模数  $S=100$ , 趋向性行为步数  $N_c=100$ , 沿同一方向前进的步数  $N_s=4$ , 繁殖代数  $N_{re}=8$ , 迁徙事件数目  $N_{el}=2$ , 迁徙概率  $P_{el}=0.5$ , 步长  $C(i)=0.1$ , 细菌间引力深度  $d_{attractant}=0.01$ , 细菌间引力宽度  $w_{attractant}=0.2$ , 细菌间斥力高度  $h_{repellant}=0.01$ , 细菌间斥力宽度  $w_{repellant}=10$ 。
- (4) BSO 算法<sup>[10]</sup>: BFO 参数如上, PSO 参数为学习因子  $c=2$ , 惯性权重  $w=1.5$ 。

3.1 优化模型后件参数

此方法中, 首先用网格对角线法<sup>[3]</sup>对模糊模型前件结构进行划分, 并采用中心和宽度都固定的高斯型隶属函数来确定前件参数, 然后用第 2 节所提到的 GA、PSO、BFO、BSO 等算法优化模糊模型的后件参数, 得到系统的动态线性方程。各算法参数选择如上所示, 搜索空间维数  $D$  为需要辨识的结论参数个数  $(r+1)c=16$ 。4 种优化算法优化后件参数的均方误差和运行时间如表 1 所示 (20 次仿真平均结果)。辨识误差曲线如图 4 所示。

表 1 优化后件参数时不同算法的均方误差

优化算法	种群规模	运行时间/s	MSE
GA	40	15.527 5	0.052 4
PSO	40	166.593 8	0.001 19
BFO	100	545.687 5	0.056 5
BSO	100	555.746 8	0.041 0




图 4 优化后件参数方法的辨识误差

3.2 优化模型全局参数

采用第 2 节介绍的前 4 种智能优化算法对模糊模型的前后件参数同时进行编码优化。搜索空间维数  $D$  为需要辨识的结论参数个数  $(3r+1)c=40$ 。在两种混合算法中, 将前后件参数分别进行编码, 用不同的优化算法进行参数优化, 需要辨识的前件参数个数为  $2r \cdot c=24$ , 后件参数个数为  $(r+1)c=16$ 。智能算法的参数如上所示, RLS 初始条件为  $P_0=0, S_0=\alpha I, \alpha=10^{-4}$ <sup>[9]</sup>。5 种优化算法优化后件参数的均方误差和运行时间如表 2 所示 (20 次仿真平均结果)。图 5 为几种全局优化方法误差曲线。

3.3 仿真结果分析

由上面的仿真结果可以看出, 前后件参数都进行优化的方法辨识精度普遍比只优化后件参数的精度要高很多, 但同时由于需要优化的参数个数增加, 计算量增大, 运行时间增长。

表 2 全局优化时不同算法的均方误差

优化算法	种群规模	运行时间/s	MSE
GA	40	34.625	0.023 6
PSO	40	946.685 2	$8.609\times10^{-4}$
BFO	100	1 199.484 0	0.012 1
BSO	100	1 246.726 8	0.019 1
PSO-RLSE	40	3 165.203 1	$1.217\times10^{-4}$




图 5 全局优化方法的辨识误差

采用 GA、PSO、BFO 3 种基本优化算法的模糊建模结果说明,无论是优化后件参数还是进行全局参数优化,3 种算法用于优化模型参数均能达到准确建模的目的。BFO 算法的辨识精度低于 PSO,是由于 BFO 的辨识精度有较少的约束。模糊模型中需要进行辨识的参数个数决定了 BFO 搜索空间维数,维数增加,满足要求而不是最优解的解增多。因此,如果搜索维数较大,要找到最优解,就必须要有有一定的约束。而且随着搜索空间维数的增加,在辨识模型的实现过程中 BFO 算法计算量增大,随机性增强。GA 全局优化能力较强,但过程复杂,有较慢的收敛速度,实时性不高。用 GA 优化 T-S 模型参数,精度不高,随机性较大。

混合优化方法 PSO-RLSE,其模糊建模精度较单一的优化方法要好得多,但是计算时间明显增长,这是由于要分别采用两种方法优化前后件参数,增加了计算量。在混合优化算法中,将需要辨识的参数分成前提参数和结论参数两个部分分别进行辨识,较前后件参数同时编码进行辨识,减少了智能算法搜索空间维数,提高了模糊辨识精度。

4 结 论

本文给出了几种智能优化算法的详细介绍并将其用于 T-S 模糊模型的辨识,通过 Matlab 仿真实验给出了仿真结果。由于 GA 本身的复杂性,其用于模糊辨识参数优化精度不高,随机性很大;PSO 算法实现简单,能快速收敛,但易陷入局部最优值,而且缺乏数学理论支撑,用 PSO 算法优化 T-S 模糊模型参数的结果相对来说还是令人满意的,因此提高模糊模型的辨识精度,改善 PSO 算法易早熟的缺点是研究的一个方向;BFO 算法能够较好地找到全局最优解,但收敛速度较慢,在 T-S 模糊模型辨识中,由于寻优空间维数大,而辨识精度约束较少, BFO 算法计算量增大,优化结果的随机性增大,导致辨识精度降低,改进 BFO 算法要在减少计算量与随机性的同时保证精度。除 GA、PSO、BFO 外,还有其他一些被人们关注和研究的智能算法,如蚁群算法、人工鱼群算法、差分进化算法等。这些算法互相渗透结合将是提高 T-S 模糊模型辨识算法性能和辨识精度的主要途径。本文介绍的将其他算法与智能算法相结合,形成混合算法辨识 T-S 模型,是提高模糊模型辨识精度的又一个有效途径。在混合算法中,虽是对模型的全局参数进行优化,但实际上是将前后件参数分别进行编码优化,这提高了辨识算法的逼近精度。

参考文献:

[1] Liu F C, Piao C J, Pei R. Analysis on the applications of fuzzy

- clustering method in fuzzy model identification [J]. *Systems Engineering and Electronics*, 2002, 24(5): 35–37. (刘福才, 朴春俊, 裴润. 模糊模型辨识中模糊聚类方法应用分析[J]. 系统工程与电子技术, 2002, 24(5): 35–37.)
- [2] Liu F C, Ma L Y. Prediction of chaos based on the nearest neighbor clustering and vector fuzzy C-means clustering[J]. *Systems Engineering and Electronics*, 2007, 29(12): 2162–2165. (刘福才, 马丽叶. 基于最邻近聚类和向量模糊 C-均值的混沌预测[J]. 系统工程与电子技术, 2007, 29(12): 2162–2165.)
- [3] Liu F C. *Fuzzy identification of nonlinear system and its application* [M]. Beijing: National Defense Industry Press, 2006. (刘福才. 非线性系统的模糊模型辨识及其应用[M]. 北京: 国防工业出版社, 2006.)
- [4] Hart E, Ross P, Corne D. Evolutionary scheduling: a review [J]. *Genetic Programming and Evolvable Machines*, 2005, 6(2): 191–220.
- [5] Wang L, Liu B. *Particle swarm optimization and scheduling algorithms* [M]. Beijing: Tsinghua University Press, 2008: 15–19. (王凌, 刘波. 微粒群优化与调度算法[M]. 北京: 清华大学出版社, 2008: 15–19.)
- [6] Yu S W, Wei Y M, Wang K. A PSO-GA optimal model to estimate primary energy demand of China [J]. *Energy Policy*, 2012, 42(C): 329–340.
- [7] Ray P K, Subudhi B. BFO optimized RLS algorithm for power system harmonics estimation [J]. *Applied Soft Computing*, 2012, 12(8): 1965–1977.
- [8] Majhi B, Panda G. Development of efficient identification scheme for nonlinear dynamic systems using swarm intelligent techniques [J]. *Expert Systems with Applications*, 2010, 37(1): 556–566.
- [9] Li C S, Wu T H. Adaptive fuzzy approach to function approximation with PSO and RLSE [J]. *Expert Systems with Applications*, 2011, 38(10): 13266–13273.
- [10] Kamyab S, Bahrololoum A. Designing of rule base for a TSK-fuzzy system using bacterial foraging optimization algorithm (BFOA) [J]. *Procedia-Social and Behavioral Sciences*, 2012, 32(12): 176–183.
- [11] Chen D B, Zhao C X. Data-driven fuzzy clustering based on maximum entropy principle and PSO [J]. *Expert Systems with Applications*, 2009, 36(1): 625–633.
- [12] Takagi T, Sugeno M. Fuzzy identification of system and its application on modeling and control [J]. *IEEE Trans. on Systems, Man and Cybernetics*, 1985, 15(1): 116–132.
- [13] Holland J H. *Adaptation in nature and artificial systems* [M]. Michigan: University of Michigan Press, 1975.
- [14] Byoung J P, Sung K O, Pedrycz W. Fuzzy identification by means of partition of fuzzy input space and an aggregate objective function [C] // *Proc. of the IEEE International Fuzzy Systems Conference Proceedings*, 1999, 1: 480–485.
- [15] Gomez-Skarmeta A F, Jimenez F. Fuzzy modeling with hybrid systems [J]. *Fuzzy Sets and Systems*, 1999, 104(2): 199–208.
- [16] Mendes J, Souza F, Araujo R, et al. Genetic fuzzy system for data-driven soft sensors design [J]. *Applied Soft Computing*, 2012, 12(10): 3237–3245.
- [17] Wu B L, Yu X H. Fuzzy modeling and identification with genetic algorithm based learning [J]. *Fuzzy Sets and Systems*, 2000, 113(3): 351–365.
- [18] Li S, Luo Y, Zhang M R. Prediction method for chaotic time series of optimized BP neural network based on genetic algorithm [J]. *Computer Engineering and Applications*, 2011, 47(29): 52–55. (李松, 罗勇, 张铭锐. 遗传算法优化 BP 神经网络的混沌时间序列预测[J]. 计算机工程与应用, 2011, 47(29): 52–55.)
- [19] Yusof R, Rahman R Z A, Khalid M, et al. Optimization of fuzzy model using genetic algorithm for process control application [J]. *Journal of the Franklin Institute*, 2011, 348(7): 1717–1723.
- [20] Pan J H. Genetic algorithm and its application study on fuzzy identification [D]. Qinhuangdao: Yanshan University, 2003. (潘江华. 遗传算法及其在模糊辨识中的研究[D]. 秦皇岛: 燕山大学, 2003.)
- [21] Kennedy J, Eberhart R C. Particle swarm optimization [C] // *Proc. of the IEEE International Conference on Neural Networks*, 1995: 1942–1948.
- [22] Cavuslu M A, Karakuzu C, Karakaya F. Neural identification of dynamic systems on FPGA with improved PSO learning [J]. *Applied Soft Computing*, 2012, 12(9): 2707–2718.
- [23] Yusup N, Zain A M, Hashim S Z M. Overview of PSO for optimization process parameters of machining [J]. *Procedia Engineering*, 2012, 29(1): 914–923.
- [24] Zhu H H, Wang Y, Wang K S, et al. Particle swarm optimization for the constrained portfolio optimization problem [J]. *Expert Systems with Applications*, 2011, 38(8): 10161–10169.
- [25] Majhi B, Panda G. Robust identification of nonlinear complex systems using low complexity ANN and particle swarm optimization technique [J]. *Expert Systems with Applications*, 2011, 38(1): 321–333.
- [26] Nanda S J, Panda G, Majhi B. Improved identification of Hammerstein plants using new CPSO and IPSO algorithms [J]. *Expert Systems with Applications*, 2010, 37(10): 6818–6831.
- [27] Chiou J S, Tsai S H, Liu M T. A PSO-based adaptive fuzzy PID-controllers [J]. *Simulation Modelling Practice and Theory*, 2012, 26(8): 49–59.
- [28] Tobati A, Barani G A, Pour H N A, et al. Balanced fuzzy particle swarm optimization [J]. *Applied Mathematical Modelling*, 2012, 36(5): 2169–2177.
- [29] Hassen T D, Ahmed M E G, Mohamed E E S. PSO based optimized fuzzy controllers for decoupled highly interacted distillation process [J]. *Ain Shams Engineering Journal*, 2012, 3(3): 251–266.

- [30] Chen D B, Wang J T, Zou F, et al. Linguistic fuzzy model identification based on PSO with different length of particles [J]. *Applied Soft Computing*, 2012, 12(11):3390–3400.
- [31] Zhao L, Qian F, Yang Y P, et al. Automatically extracting T-S fuzzy models using cooperative random learning particle swarm optimization [J]. *Applied Soft Computing*, 2010, 10(3):938–944.
- [32] Passino K M. Biomimicry of bacterial foraging for distributed optimization and control[J]. *Control Systems Magazine*, 2002, 22(3):52–67.
- [33] Verma O P, Hanmandlu M, Kumar P, et al. A novel bacterial foraging technique for edge detection[J]. *Pattern Recognition Letters*, 2011, 32(8):1187–1196.
- [34] Abd-Elazim S M, Ali E S. Bacterial foraging optimization algorithm based SVC damping controller design for power system stability enhancement[J]. *Electrical Power and Energy Systems*, 2012, 43(1):933–940.
- [35] Alejandra G M, Delgado A, Carvalho J D. A novel multiobjective optimization algorithm based on bacterial chemotaxis[J]. *Journal of Engineering Applications of Artificial Intelli-*

*gence*, 2008, 23(3): 292–301.

- [36] Tabatabaei S M, Vahidi B. Bacterial foraging solution based fuzzy logic decision for optimal capacitor allocation in radial distribution system[J]. *Electric Power Systems Research*, 2011, 81(4): 1045–1050.
- [37] Li Y N. The algorithm of bacterial foraging optimization[D]. Harbin: Harbin Institute of Technology, 2009. (李亚楠. 菌群优化算法的研究[D]. 哈尔滨: 哈尔滨工业大学, 2009.

## 作者简介:

**刘福才**(1966–),男,教授,博士研究生导师,博士,主要研究方向为模糊辨识与预测控制、混沌系统预测控制、电力拖动及其计算机控制。

E-mail: lfc@ysu.edu.cn

**窦金梅**(1987–),女,硕士研究生,主要研究方向为模糊辨识与控制、智能优化算法。

E-mail: jinmeidou@yahoo.cn

**王树恩**(1968–),男,博士研究生,主要研究方向为模糊系统辨识与控制。

E-mail: shuenwang1968@263.net